PRESENTAZIONE TECNICA

Storia del progetto: problemi ricorrenti e come li abbiamo risolti

Ricostruita dalla cronologia git: 90 commit in tre giorni, tre contributori, tre componenti

Il progetto in numeri

90
commit

3
contributori

3
giorni (14–16 ottobre)

192
test del solo voice

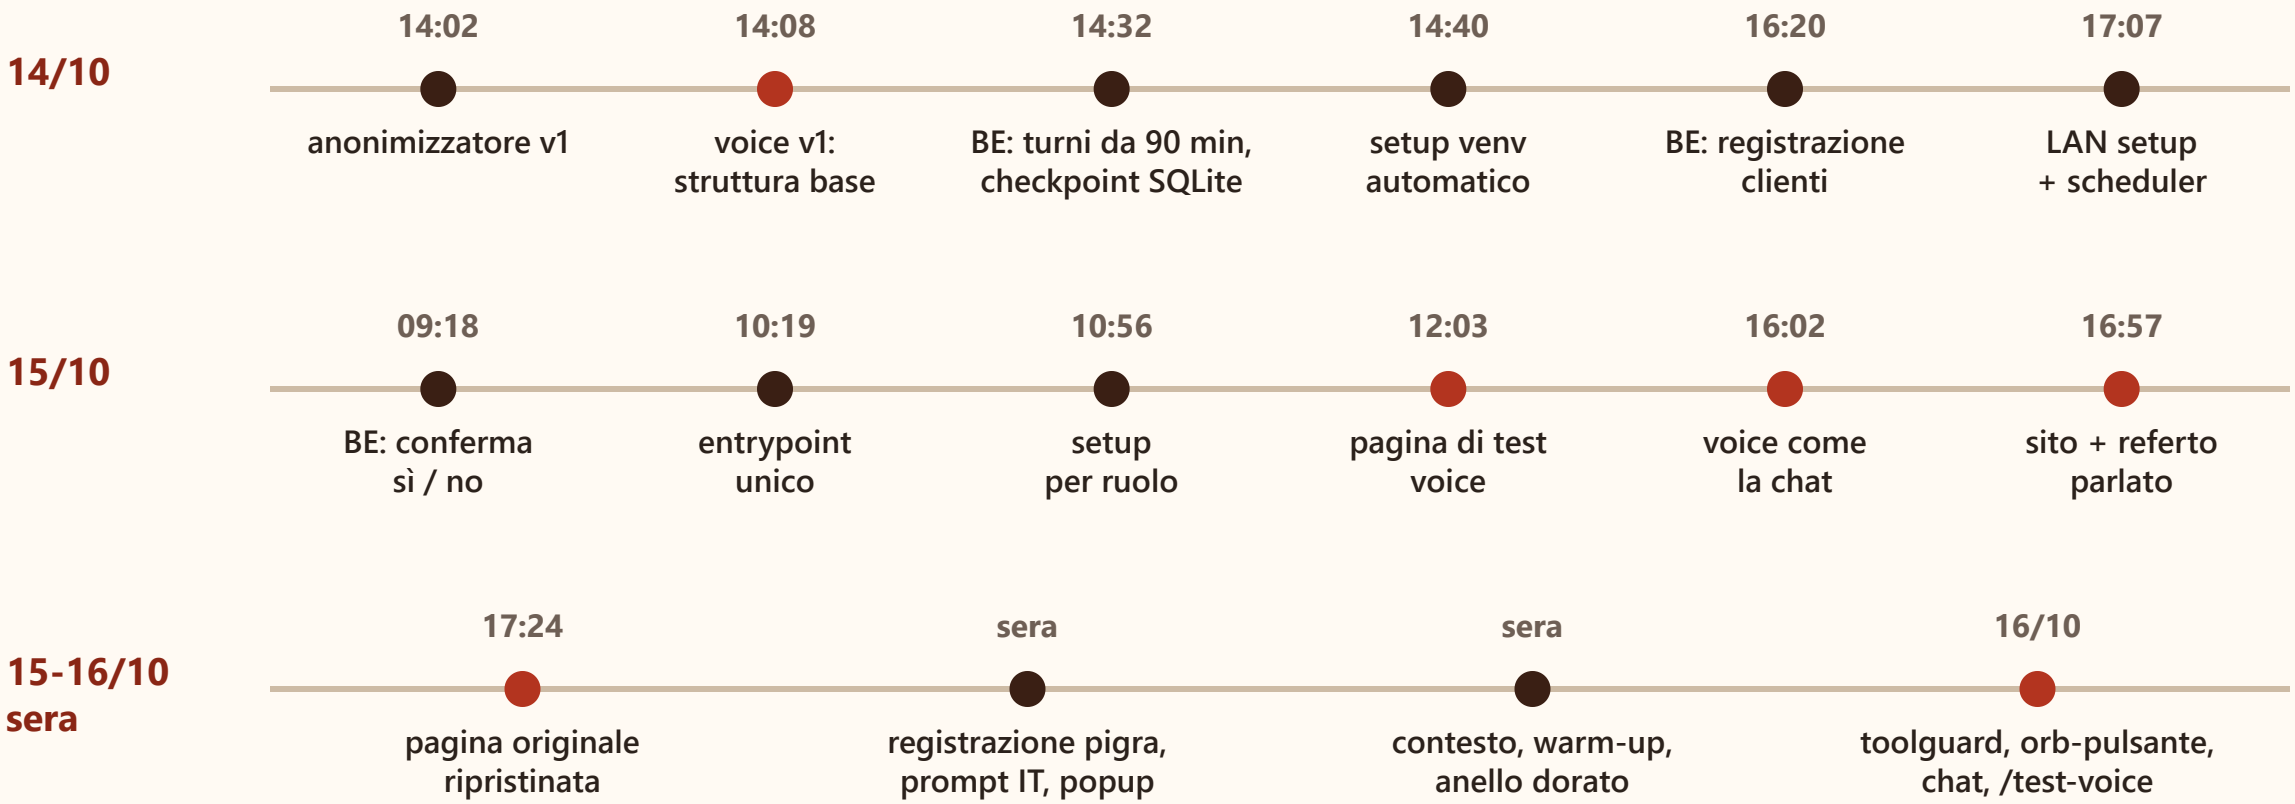
Dimensioni (righe)

Parte	Righe
voice (codice, pagine, sito)	6.272
voice (test)	2.358
backend	2.809
chat	1.420
frontend	1.212
lan + setup + entrypoint	1.327
test del backend	1.738

Ritmo

- 14/10: **39** commit — nascono i tre componenti
- 15/10: **50** commit — setup per ruolo, entrypoint, sito, rifacimento del voice
- 16/10: rifiniture (orb, popup, contesto)
- ~21.000 righe aggiunte, ~4.000 tolte nel periodo

Linea del tempo



rosso = lavoro sul componente VOICE · marrone = BE, CHAT, setup e LAN

Ricorrente 1 · Setup del venv e conflitti di merge

PROBLEMA

Un solo `requirements.txt` e `setup_env.py` toccati da più persone: **7 modifiche su 2 giorni**, commit come «mio setup: tenere questa versione» e «fix setup env dopo merge sbagliato»; installazioni pesanti su macchine che non servivano.

COME L'ABBIAMO RISOLTO

- Cartella spostata e stabilizzata: `tools/env_setup` → `setup/`
- **Requisiti per ruolo** (base, be, chat, voice, dev): un file per persona → niente conflitti
- Stato in `.venv/.setup_state.json` con **hash sha256**: se un file cambia, il setup riparte da solo
- Installazione **pacchetto per pacchetto** con output live e pacchetti opzionali tollerati
- Guardia: il venv non può mai nascere fuori dalla repo

Catena: b8c1712 (primo setup) → 1aa2df6 → 1c172bd → 58e1f38 → 5af2bf3 (fix dopo merge) → 3fc4dbb (per ruolo)

Ricorrente 2 · Ogni macchina deve sapere chi è e dove sta il BE

PROBLEMA

Tre PC, tre ruoli, IP che cambiano, avvio nell'ordine giusto, firewall: 7 modifiche a `lan/machine_setup.py` in due giorni («fix su lan per dare i ruoli a ciascuna macchina»).

COME L'ABBIAMO RISOLTO

- **Identità** della macchina in `lan/macchina.json` (ruolo + IP rilevato con un socket UDP, mai in git)
- **Un solo comando**: `entrypoint/avvia.py` (git → identità → setup → .env → firewall → attesa BE → avvio)
- **Cancello sul BE**: CHAT e VOICE aspettano che `/api/health` risponda
- **Servizi extra** per ruolo in `lan_config.json` (API del sito :8002, frontend :8080) fermati insieme con Ctrl+C
- **Avvio automatico** con Scheduled Task per la demo: il presentatore tocca un solo PC (`--attendi`)

5c0ad2b (ruoli) → 96301d1 (entrypoint) → 3fc4dbb (identità) → d183fb2 → 81084e4 (servizi extra)

Ricorrente 3 · La pipeline vocale col modello vero (cd1be40)

Sintomo	Causa	Fix
TTS si rompeva	Piper 1.8 ha cambiato API	gestite sia le API ≤ 1.2 sia ≥ 1.3
Voce con tono sbagliato	frequenza del modello ignorata dal client	annunciata nell'evento `ready`
Prima chiamata lentissima	STT/TTS ricaricati a ogni chiamata	modelli condivisi e **precaricati** all'avvio
Pausa 6 volte troppo lunga	VAD contava i frame (il browser ne manda da 128 ms)	tempo misurato sull'audio ricevuto
Bot che non si lascia interrompere	barge-in non annullava un turno in «thinking»	contatore di generazione + rumore breve ignorato
Prenotazioni doppie	POST ritentato dopo un timeout in lettura	**mai** ritentare una richiesta non idempotente
Test che dipendevano dal PC	.env e interprete della macchina	conftest isola, stub BE, 119 test ermetici

Ricorrente 4 · Il parlato non è testo

PROBLEMA

Whisper **tiny** sbaglia numeri e nomi; il suo «prompt iniziale» veniva ripetuto al posto del nome; «alle 20 e 30» diventava 20:00; una pausa dentro un numero di telefono spezzava la frase in due.

COME L'ABBIAMO RISOLTO

- Modello **small** di default; il prompt è **spento** (f073570)
- Cifre parlate normalizzate («tre tre tre…») e **frammenti uniti** tra una frase e l'altra
- Telefono letto **cifra per cifra** e validato con `phonenumbers`
- Il BE finto capisce «alle 20 e 30» (d18d33c, trovato in una prova col modello reale)
- Numeri, date e orari **a parole** prima della sintesi; allucinazioni di Whisper scartate

Ricorrente 5 · I modelli piccoli sbagliano: l'LLM propone, il codice decide

PROBLEMA

llama3.2 chiamava `create_reservation` su saluti e frasi senza senso: prenotazioni fantasma; passava la stringa «null»; inventava piatti per le allergie. Oggi, con gemma4, annuncia gli strumenti invece di usarli.

COME L'ABBIAMO RISOLTO

- **Conferma esplicita** (06d45e1): l'LLM può solo *proporre*; riepilogo scritto dal codice e azione solo dopo un «sì» intero («sì ma alle 21» non vale)
- Argomenti «null»/«nessuna» trattati come assenti; prenotazione proposta solo se nei messaggi c'è una richiesta (3baf68c)
- **Allergie**: risposta costruita dal codice dal menu, mai dal modello (c7c1599)
- **Voice**: filtro `toolguard` sulla prima frase, un nuovo tentativo, poi frase neutra
- Modello scelto automaticamente tra quelli installati che sanno usare gli strumenti (4c7f0a2)

Ricorrente 6 · La privacy decide l'architettura

PROBLEMA

Nome e telefono servono al ristorante ma l'LLM non deve vederli; un nome usato come identificativo era già un dato personale.

COME L'ABBIAMO RISOLTO

- `POST /api/customers` è l'**unico** punto con dati personali → `customer_id` anonimo (6f64a50)
- Con la registrazione attiva solo il **proprietario** legge, modifica o cancella (404 per gli altri)
- Nei tool il `customer_id` arriva **dalla sessione**, mai dal modello
- Anonimizzatore della CHAT portato nel voice con gli **stessi segnaposto**; rete di sicurezza `scrub_pii`
- Registrazione a voce **solo quando serve** (si parla di prenotare); retention: `maintenance purge` dopo 90 giorni

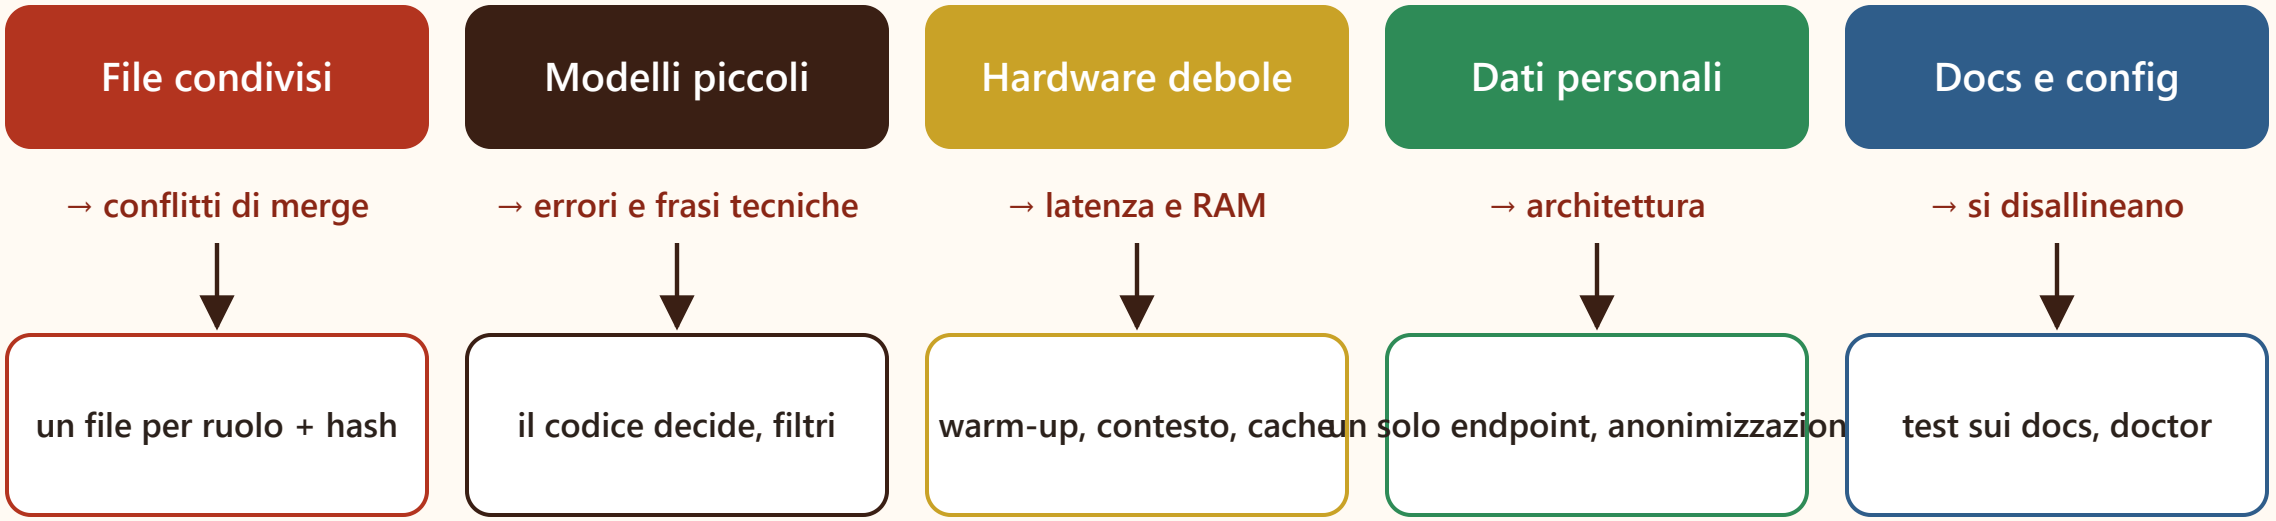
Ricorrente 7 · Docs e configurazione che si disallineano

Cosa	Cosa è successo	Decisione
.env.example	10 modifiche	test_docs controlla che ogni variabile documentata esista davvero
README_VOICE.md	10 modifiche	test che legge il README e verifica moduli e comandi citati
Pagina di test	riscritta e perdute le animazioni	ripristinata dall'originale (55069b6): **estendere, non riscrivere**
Comandi nei docs	`voice\voice` diventato «voiceoice»	backslash mangiati da caratteri di controllo: ripristinati
Branch	lavoro rimasto su savov e non su main	merge di recupero (27b67cc)

Gli ultimi giorni: problema → decisione

Problema	Decisione
Saluto troppo lungo e «avido»	Saluto breve; nome e telefono solo quando si parla di prenotare, poi la richiesta riparte da sola
Bot che rispondeva in inglese per via del prompt	Prompt **in italiano**, lingua del cliente se la conosce
Il cliente non vedeva cosa era stato prenotato	Popup di riepilogo, chiuso 4 s dopo il «sì» finale (solo voce)
Modello locale lento su portatile	Contesto 8k, warm-up, id anonimo condiviso, 20 scambi poi nuova sessione, 4° giro chiude
«Chiamo get_menu… vuole che verifichi?»	Filtro sulla prima frase + un nuovo tentativo
Orb senza segnali chiari	Anello dorato: sottile/lento → si ispessisce → ondeggia mentre parla
Pulsante + pannello con bottoni	Il pulsante «Prenota a voce» diventa l'orb; chat «Scrivi» a parte; test su /test-voice

Le cinque cause dietro i problemi ricorrenti



Sette problemi, cinque cause: ogni decisione di progetto nasce da un incidente reale.

Cosa resta aperto

Rischi e limiti

- La prova **a tre macchine** non è ancora stata fatta dal vivo
- Il BE scrive data e customer_id in cima al prompt: ogni nuovo cliente fa rileggere tutto al modello
- Il BE a volte risponde con testo invece di usare gli strumenti
- Il riconoscimento è fissato sulla lingua dell'.env: altre lingue non sono trascritte bene
- Nessun endpoint «elenco prenotazioni del cliente»: la pagina ricorda i codici nel browser

Prossimi passi

- Spostare le righe per cliente in fondo al prompt del BE
- Allineare il prompt vocale del BE a `voice/src/voicebot/prompts.py`
- Provare il flusso su macchine più potenti e misurare i tempi
- Valutare il cognome solo quando c'è una prenotazione simile (serve il BE)
- Provare Docker (`voice/Dockerfile` non è mai stato costruito qui)