Flowchart del flusso del codice · AI 4 Restaurants (VOICE)

Ovale = inizio/fine · rettangolo = azione · rombo = decisione · parallelogramma = ingresso/uscita (rete, audio) · doppio bordo = sottoprocesso nel BE

1 · AVVIO DI UNA MACCHINA (entrypoint/avvia.py)

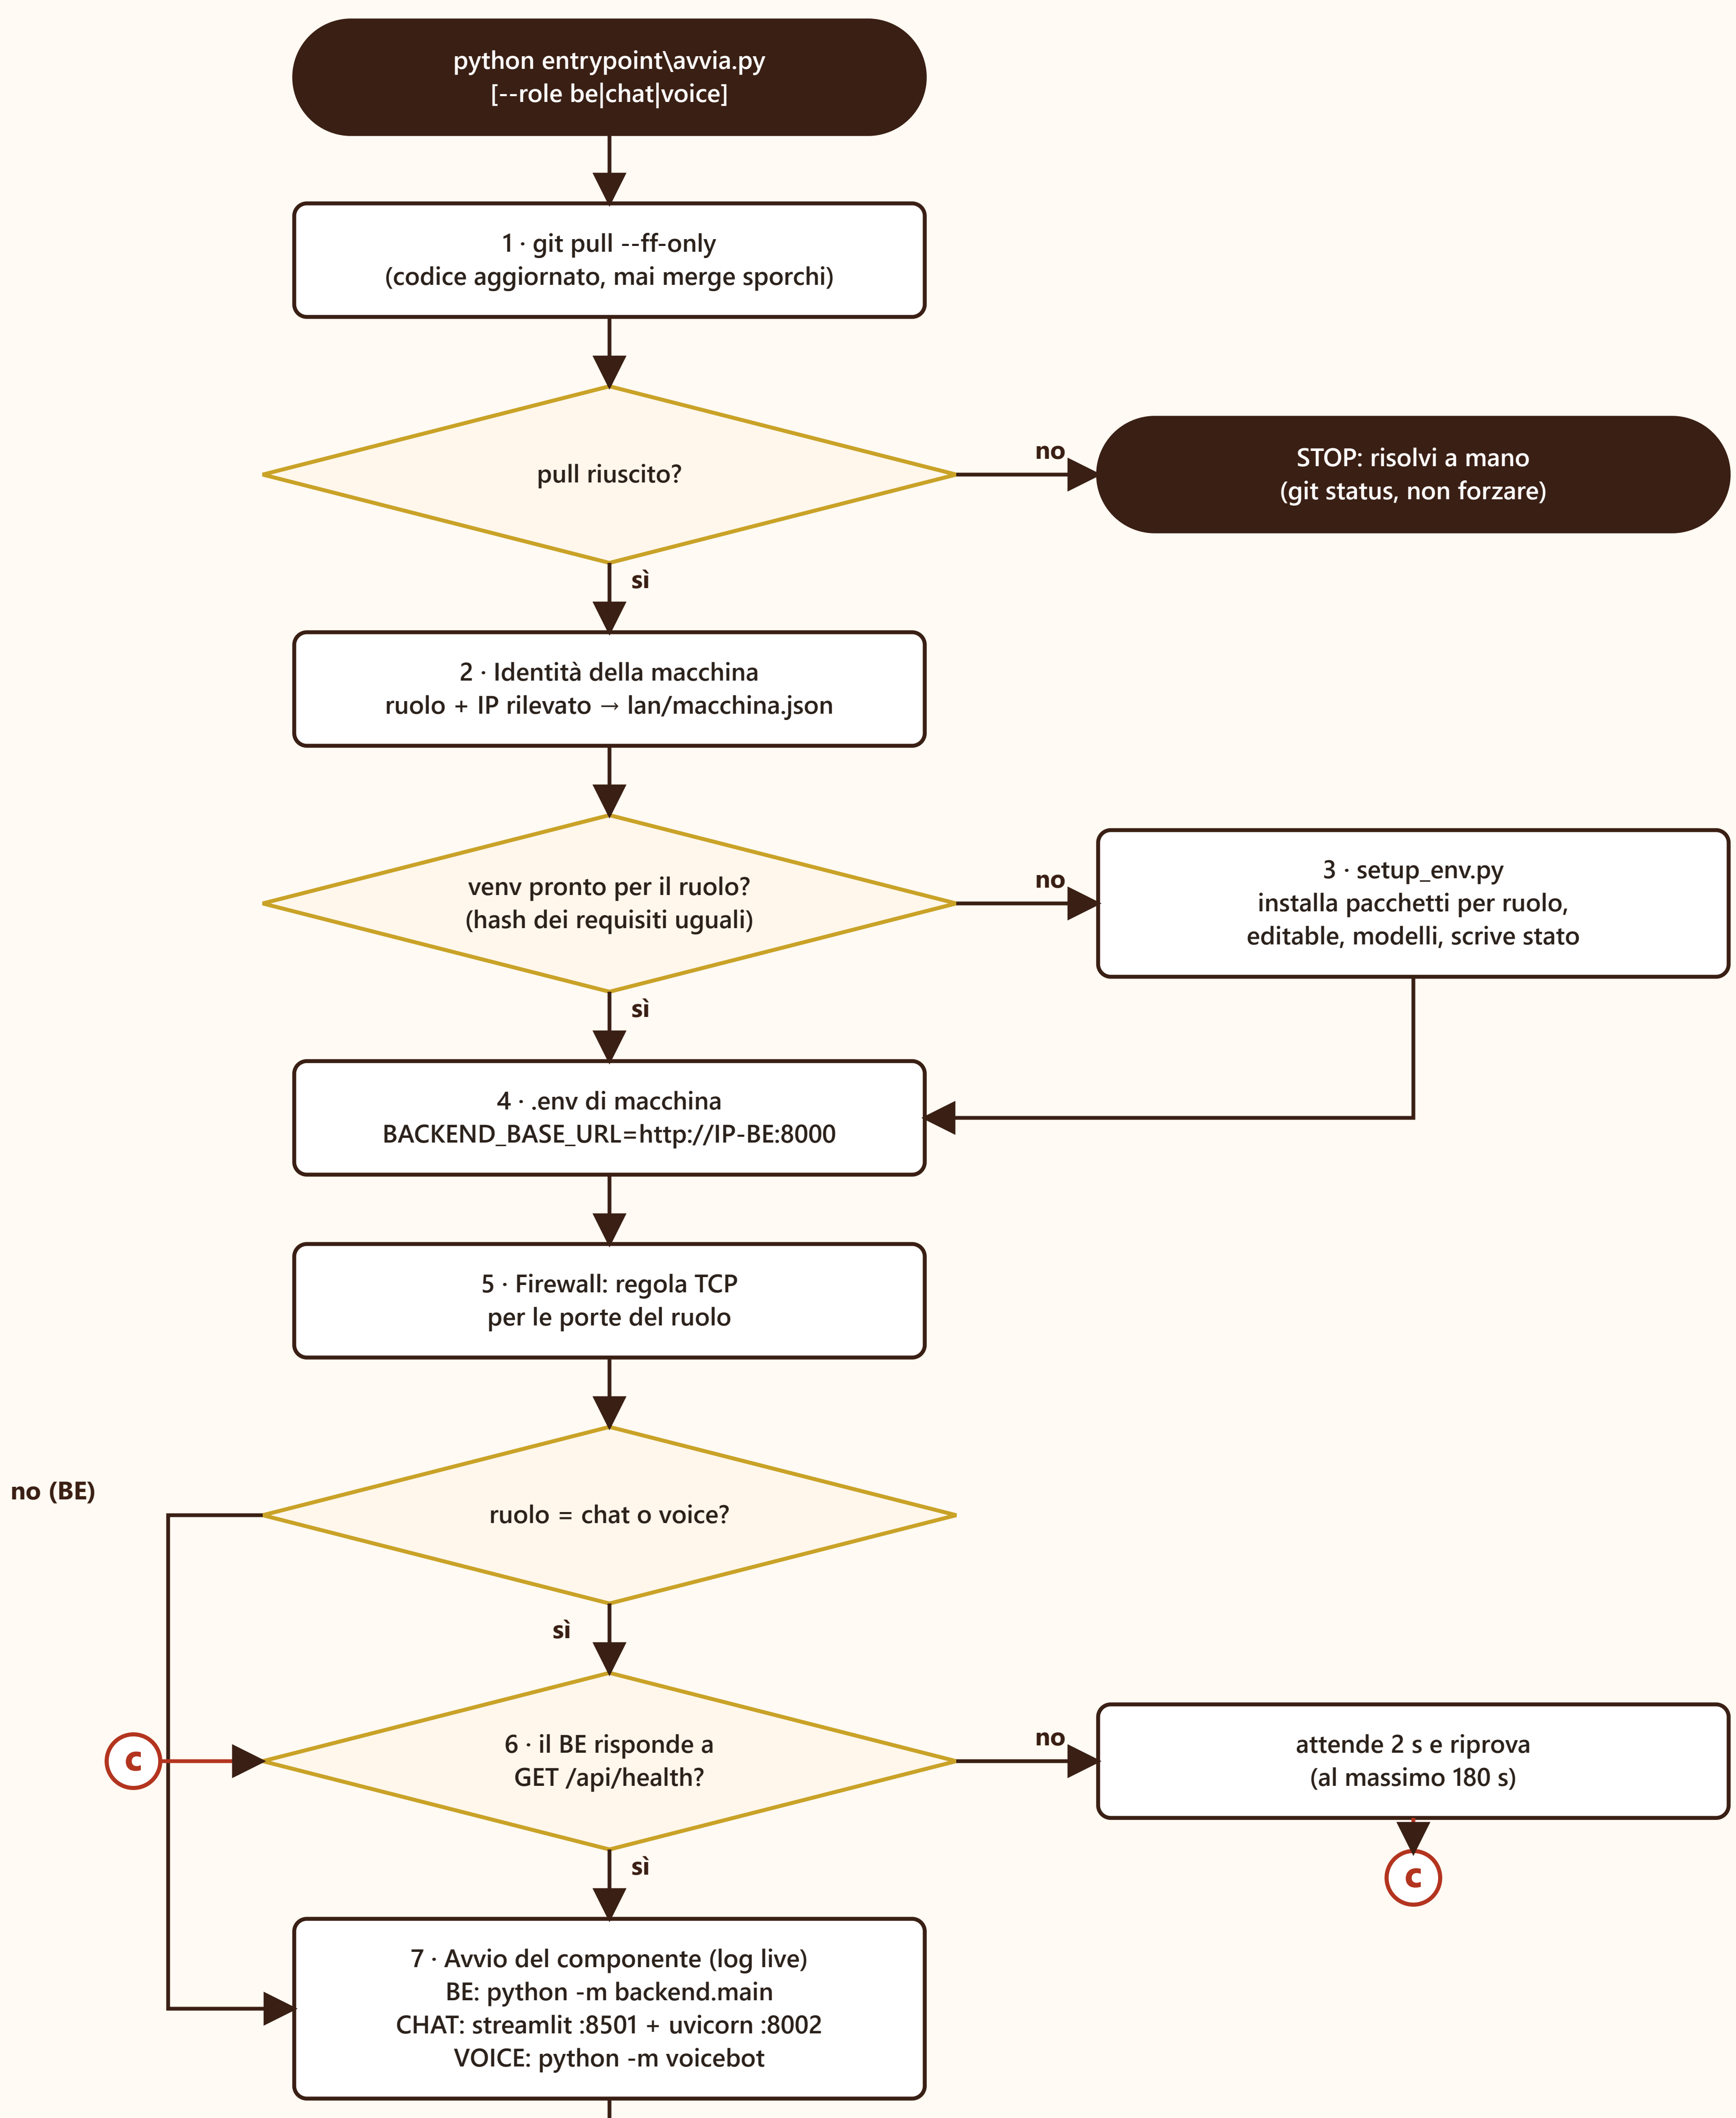
python entrypoint\avvia.py [--role be|chat|voice]
1 · git pull --ff-only (codice aggiornato, mai merge sporchi)
pull riuscito?
no
STOP: risolvi a mano (git status, non forzare)
sì
2 · Identità della macchina ruolo + IP rilevato → lan/macchina.json
venv pronto per il ruolo? (hash dei requisiti uguali)
no
3 · setup_env.py installa pacchetti per ruolo, editable, modelli, scrive stato
sì
4 · .env di macchina BACKEND_BASE_URL=http://IP-BE:8000
5 · Firewall: regola TCP per le porte del ruolo
no (BE)
ruolo = chat o voice?
sì
C
6 · il BE risponde a GET /api/health?
no
attende 2 s e riprova (al massimo 180 s)
C
sì
7 · Avvio del componente (log live) BE: python -m backend.main CHAT: streamlit :8501 + uvicorn :8002 VOICE: python -m voicebot

2 · IL BE E IL VOICE SI PREPARANO

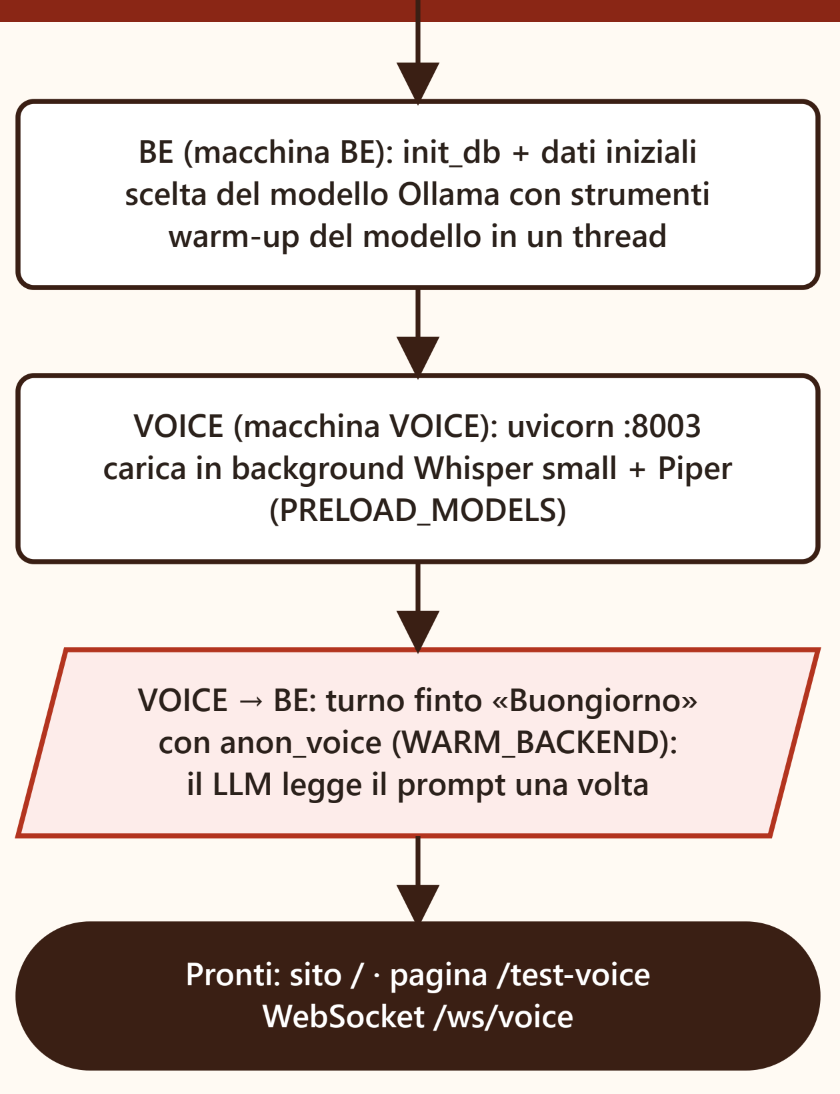
BE (macchina BE): init_db + dati iniziali scelta del modello Ollama con strumenti warm-up del modello in un thread
VOICE (macchina VOICE): uvicorn :8003 carica in background Whisper small + Piper (PRELOAD_MODELS)
VOICE → BE: turno finto «Buongiorno» con anon_voice (WARM_BACKEND): il LLM legge il prompt una volta
Pronti: sito / · pagina /test-voice WebSocket /ws/voice

3 · UNA CHIAMATA (pipeline/session.py + orchestrator.py + BE)

Il cliente tocca «Prenota a voce» (il pulsante diventa l'orb)
Browser: microfono 16 kHz → WebSocket /ws/voice
D
modelli STT/TTS pronti?
no
evento loading: attende (max 120 s)
D
sì
evento ready + saluto breve «Come posso aiutarla?» (Piper)
A
ASCOLTO: audio PCM → VAD (blocchi da 128 ms / frame da 20 ms)
A
no
voce ≥ 250 ms e poi pausa ≥ 600 ms?
sì
il bot stava parlando e la voce dura ≥ 300 ms? (barge-in)
sì
annulla il turno, svuota l'audio in coda, evento barge_in
no
STT faster-whisper small utterance → testo
A
sì
testo vuoto o «allucinazione»?
no
fase REGISTRAZIONE in corso?
sì
contacts: estrae nome e telefono (cifre a parole, validati E.164)
dati mancanti
A
B
confermati
no
non registrato e parla di prenotare? (wants_booking)
sì
avvia la registrazione: «Mi dice il suo nome e un numero di telefono?»
A
no
c'è un referto in attesa del «sì» finale?
sì
«sì» breve → popup si chiude dopo 4 s «no» → chiede cosa cambiare altro → prosegue verso il BE
A
no
contesto pieno? (≥ 20 scambi senza prenotare)
sì
nuova sessione BE + recap parlato 3° volta: avviso · 4° volta: fine chiamata
A
no
Anonimizza: regex + spaCy → [NOME_1], [TELEFONO_1]
B
POST /api/chat/stream message + session_id + customer_id
BE · process_message() 1 proposta in attesa + «sì» → esegue lo strumento 2 allergie → risposta scritta dal codice 3 altrimenti LLM + strumenti (LangGraph) 4 create/modify/cancel → riepilogo «Confermi?»
Token SSE, parola per parola la prima frase (≥ 40 caratteri) è trattenuta
parla di strumenti, chiede un permesso inutile o «offre» senza dare?
sì
toolguard: scarta e riprova 1 volta con NUDGE; se ancora sì → frase neutra
no
Ripristina i segnaposto (mai mezzo segnaposto detto a voce)
TTS Piper frase per frase speakable(): codici «R E S, 9 A 8 B...»
Audio PCM → WebSocket → browser + eventi reply · reservation · ...
A
no
la risposta contiene un codice RES-...?
sì
GET /api/reservations/{codice} (solo il proprietario)
Referto detto dal codice (non dall'LLM) evento reservation → popup riepilogo contatori del contesto a zero
A
no
fine chiamata? (call_ended · orb · inattività 60 s)
sì
Chiusura: il pulsante torna «Prenota a voce»